

Rudarenje podataka LoRaWAN mreže

Ante Lojić Kapetanović

September 10, 2019

FESB, Sveučilište u Splitu

1. Uvod i motivacija
2. Prediktivne metode
3. Predloženi RNN model
4. Rezultati
5. Zaključak

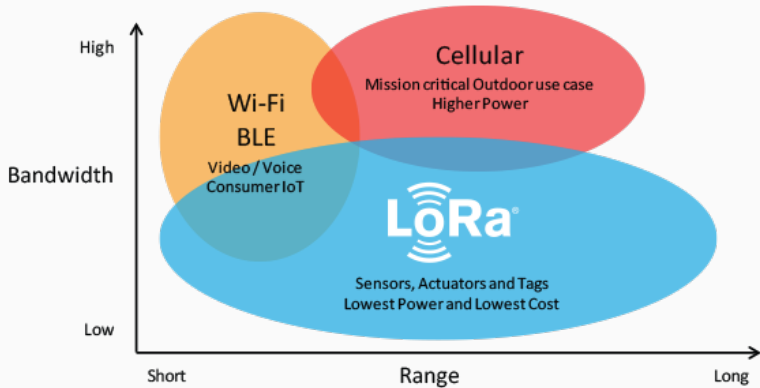
Uvod i motivacija

LoRaWAN - Long Range Wide Area Network

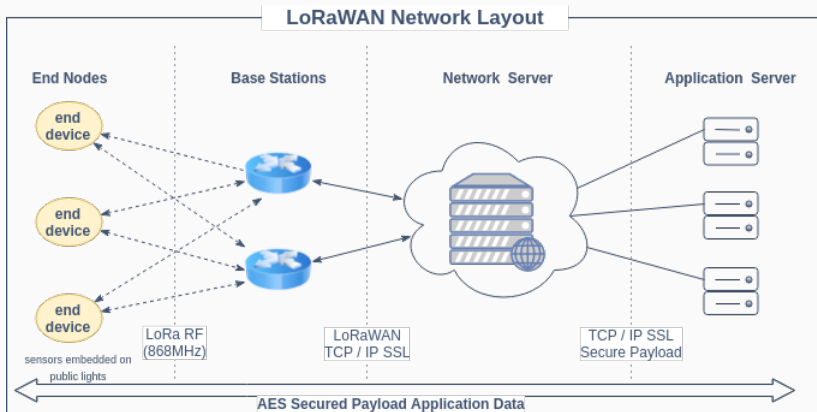
LoRaWAN - dalekosežna mreža širokog područja definirana je kao protokol kontrole pristupa mediju (MAC) za mreže širokog područja (WAN).

Dizajnirana je tako da zadovoljava ključna svojstva uređaja u IoT mreži:


- dalekosežno povezivanje
- skalabilnost
- energetska učinkovitost



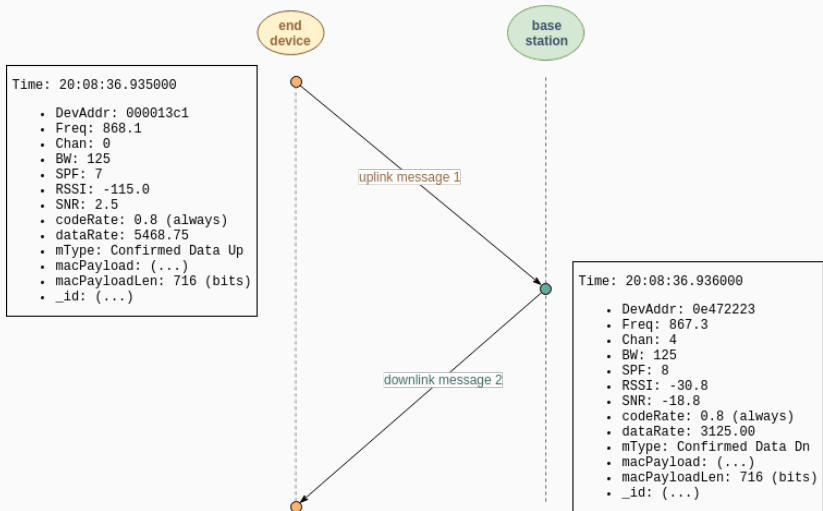
Arhitekturni pregled mreže



Svebølle mrežna topologija



Komunikacijski model za Svebølge implementaciju



Je primjena prediktivnih statističkih metoda na mjerene podatke sa bazne stanice u Swebølleu i ispitivanje mogućnosti predviđanja uspješno transmitiranih LoRa poruka za dani interval vremena u budućnosti.

Uspješnom predikcijom aktivnosti krajnjih uređaja za blisku budućnost osigurao bi se prostor definiranju učinkovitijih pristupnih protokola što bi posljedično rezultiralo boljom mrežnom propusnošću i pouzdanošću same mreže ali i energetsom efikasnošću.

Prediktivne metode

Struktura mjerenih podataka

- Podaci su prikupljeni kroz 5 mjeseci
- 689k mjerenja su snimljene na jednoj baznoj stanici
- Mjerene značajke
 - Time
 - DevAddr
 - Freq, Chan, BW, CR, DR
 - RSSI, SNR
 - crcStatus, mType, macPayload

Transformacija snimljenih podataka u vremensku seriju

Vremenska serija je niz sukcesivno raspoređenih elemenata indeksiranih u vremenskom redoslijedu pri čemu su elementi vremenski jednako razmaknuti.

Kako bismo kreirali vremensku seriju, jedina bitna značajka podatkovnog seta je aktivnost uređaja u promatranom prošlom trenutku. Za svaki trenutak, gdje je trenutak u rezoluciji sekunde, zastavica aktivnosti je dodijeljena na način:

- 1 - uređaj je bio aktivan u promatranom trenutak
- 0 - uređaj nije bio aktivan u promatranom trenutku

- Moving average / weighted moving average
- Autoregressive integrated moving average (ARIMA)
- Holt's winter method
- Vector auto regression (VAR)
- Recurrent neural network (RNN)
- Reinforcement learning (RL)


Predloženi RNN model

Prepoznaju regularnosti i uzorke promatranog seta podataka, uče iz prošlog iskustva i osiguravaju mogućnost zaključivanja na temelju izlaznih podataka.


Jednostavne neuralne mreže nisu namjenjene za prognoziranje vremenskih serija jer su limitirane s mogućnošću pamćenja historijskih podataka.

RNN mreža (Reccurent Neural Network)

RNN sadrži petlje (povratne veze) koje osiguravaju ustrajnost informacije.



Raspakirana RNN mreža



Problem kratkoročne memorije

Ako je sekvenca podataka preduga, RNN mreža će imati problem pri prenošenju informacija iz historijskih momenata u kasnije momente. Razlog je jer tijekom povratne propagacije (*back propagation*), RNN mreže pate od problema nestajućeg gradijenta (gradijent se smanjuje tijekom vremena povratne propagacije).


$$\text{nova težina} = \text{težina} - \text{stopa učenja} \times \text{gradijent}$$

$\text{gradijent} = 0 \rightarrow \text{nova težina} = \text{težina} \rightarrow \text{RNN mreža prestaje učiti}$

LSTM mreže (Long Short-Term Memory) u pomoć!

Promjena unutrašnje strukture RNN ćelije osigura se regulacija protočnosti informacije.

Unutrašnjost svake LSTM ćelije je realizirana s mehanizmima zvanim **vrata** koja kroz treniranje uče koji podaci sekvence su bitni a koji mogu biti odbačeni.



'Forget' vrata

određuju koju informaciju odbaciti iz *stanja ćelije* koristeći sigmoidnu funkciju koja na izlazu daje rezultate između 0 (u potpunosti odbaciti) i 1 (u potpunosti prihvatiti)

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

gdje je

x_t trenutni ulazni vektor podataka;

h_{t-1} prethodna vrijednosti izlaza ćelije;

W_f pridružena težinska vrijednost;

b_f je dodani *bias*.

određuju koja nova informacija će biti upisana u *stanje ćelije*.

Prvo, sigmoidna funkcija odlučuje koju vrijednost ažurirati:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

gdje je

x_t trenutni ulazni vektor podataka;

h_{t-1} prethodna vrijednosti izlaza ćelije;

W_i pridružena težinska vrijednost;

b_i je dodani *bias*.

...nakon toga, *tanh* sloj kreira vektor kandidata za trenutno stanje ćelije:

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

gdje je

x_t trenutni ulazni vektor podataka;

h_{t-1} prethodna vrijednosti izlaza ćelije;

W_C pridružena težinska vrijednost;

b_C je dodani *bias*.

određuju što ide na izlaz promatrane ćelije.

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

where

x_t trenutni ulazni vektor podataka;

h_{t-1} prethodna vrijednosti izlaza ćelije;

W_o pridružena težinska vrijednost;

b_o je dodani *bias*.

Izlaz je baziran na filtriranoj verziji *stanja ćelije*.


$$h_t = o_t * \tanh(C_t)$$


gdje je C_t novo stanje dobiveno kroz: $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$

Rezultati


1. čišćenje
2. čisti podatkovni set → vremenska serija
3. kreiranje sekvenca
4. randomiziranje sekvenca
5. podjela podatkovnog seta na set za trening i set za validaciju rezultata

Validacijski rezultati





Validacija rezultata



Za $MAE=2s$, 0.35% pogrešnih predikcija.

Procjena vjerojatnosti transmisije za proizvoljni budući vremenski period


Za dani vremenski period (n sekunda) vjerojatnost uspješne transmisije LoRa poruke s krajnjeg uređaja na baznu stanicu bi trebala rasti kako se povećava vremenski period (n postaje veći).

$$n = 0 \Rightarrow p_{st} = 0$$

$$n \in \langle 0, +\infty \rangle \Rightarrow p_{st} \in \langle 0, 1 \rangle$$

$$n = \infty \Rightarrow p_{st} = 1$$

Estimated probability of successful transmission of messages



Zaključak

- **Multivarijatna vremenska serija** umjesto jednostavne vremenske serije: promatrati ne samo prethodne historijske događaje za specifični uređaj nego i za ostale uređaje
- **Veće sekvence za treniranje modela**
- **Sekvenčne predikcije** umjesto od-točke-do-toče predikcije

Pitanja